

# Using Machine Learning Models

数据科学 – 机器学习模型入门

July 2020 Microsoft Reactor | Ryan Chung

```
led by player
;.load_image("kg.png")
ICTIZE Dog object and create True
5 self).__init__(image = Dog.image)
                 bottom = games, se
re = games.Text(value = 0, stee
   Annae Tayler on the second
:reen.add(self.score)
```



## Ryan Chung

Instructor / DevelopIntelligence Founder / MobileDev.TW

@ryanchung403 on WeChat Ryan@MobileDev.TW





# Reactor







developer.microsoft.com/reactor/
@MSFTReactor on Twitter

#### DS On-line Workshop agenda 数据科学在线研讨会议程

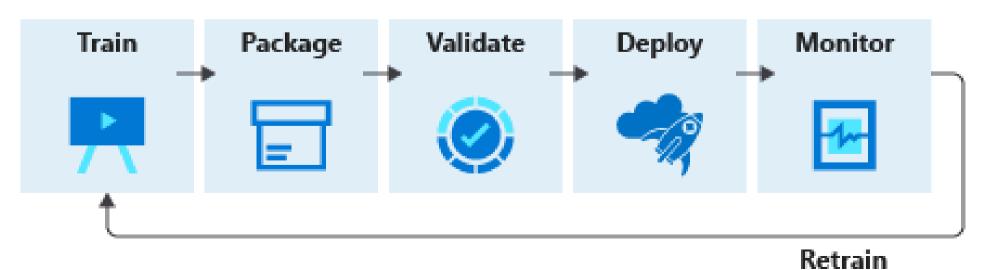
19:30	Welcome 开场						
19:35	Overview of ML 机器学习介绍						
20:00	How to choose Machine Learning Algorithm 如何选择算法						
20:20	5 -minute lab break 中场休息 / 实作练习						
20:25	The Workflow and Evaluation for ML 机器学习流程与评估指针						
20:45	Intro to Azure Machine Learning Solutions 微软机器学习解决方案						
21:00	Event end 研讨会结束						

## Azure Machine Learning 微软Azure机器学习

- 云端环境
- 可以进行模型的训练/部署/自动化/管理/追踪
- 适用于
  - 传统机器学习 / 深度学习 / 监督式学习 / 非监督式学习
- 使用弹性
  - 可自行撰写Python/R 或 使用Azure ML 图形化界面



#### Azure Machine Learning Model Workflow



## 机器学习

#### 定义

• 计算机算法可以透过经验来自动学习(Tom Mitchell)

#### 种类

- 监督式学习 (分类、回归)
- 非监督式学习(分群、关联)
- 强化学习(实时、脱机)

## 监督式学习

#### 分类

- 是什么(已知标签)
- 是或不是(二元判断)

#### Analyze image:

輸入一個圖片網址,然後按下分析圖片按鈕.

Image to analyze: https://www.petmd.com/site 分析圖片

Response:

```
"categories": [
     "name": "动物 猫",
     "score": 0.99609375
],
"color": {
   "dominantColorForeground": "Black",
   "dominantColorBackground": "Brown",
   "dominantColors":
     "Black",
     "Brown",
     "White"
   "accentColor": "BD760E",
  "isBwImg": false,
"isBWImg": false
},
"description": {
   "tags": [
     "猫",
     "室内",
     "白色",
     "看着",
```

Source image:



白色的猫

#### 修改范例出现预测结果摘要

- Predictions Array
- probability > 0.8
- tagName == "Sky"



應該是天空! (信心:1)



不是天空吧

## 监督式学习

#### Regression 数值

• 数值预测(房价、温度、销售量)

engine- size	fuel- system	bore	stroke	compression- ratio	horsepower	peak- rpm	city- mpg	highway- mpg	price
130	mpfi	3.47	2.68	9	111	5000	21	27	13495
130	mpfi	3.47	2.68	9	111	5000	21	27	16500
152	mpfi	2.68	3.47	9	154	5000	19	26	16500
109	mpfi	3.19	3.4	10	102	5500	24	30	13950
136	mpfi	3.19	3.4	8	115	5500	18	22	17450
136	mpfi	3.19	3.4	8.5	110	5500	19	25	15250
136	mpfi	3.19	3.4	8.5	110	5500	19	25	17710

## 监督式学习

#### 常见使用案例

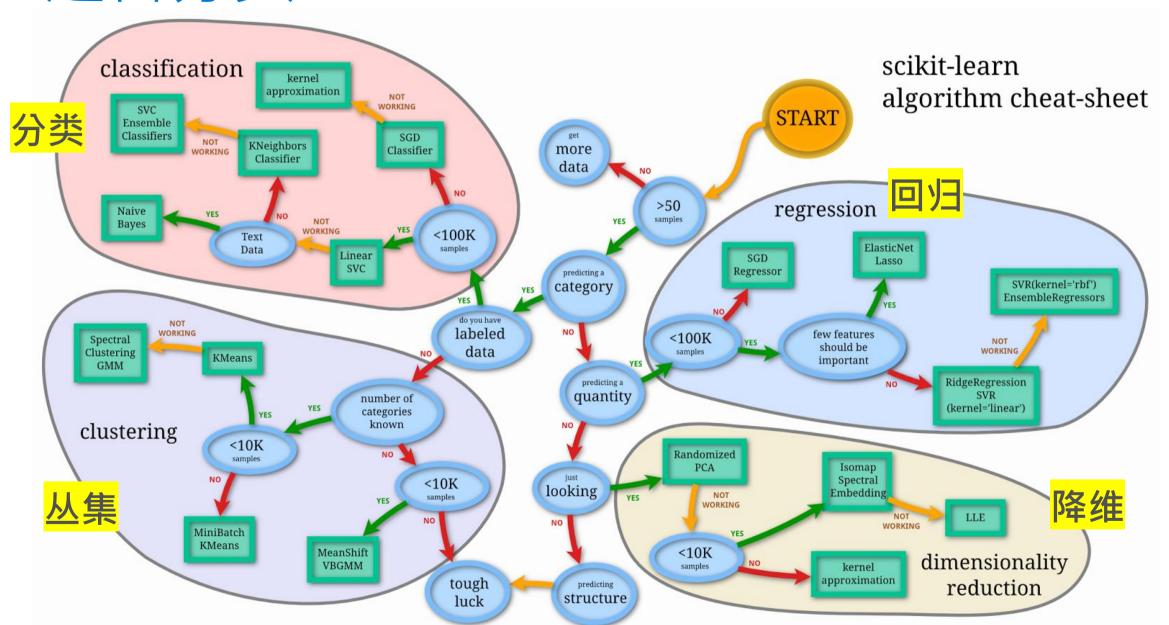
- 图片分类
- · 光学文字分类(OCR)
- 脸部辨识
- 情绪分析(sentiment)
- 自然语言处理
- 机器翻译
- 字幕产生
- 事件侦测

## 题目分类

#### 监督式/非监督式 VS. 数据连续/可数

数据型态 Data Type	监督式学习 Supervised	非监督式学习 Unsupervised	
Discrete 离散的	分类 Classification	丛集 Clustering	
Continuous 连续的	回归 Regression	降维 Dimensionality Reduction	

#### 题目分类



## 如何选择?

- 你的目标是什么?
  - 参考后面两页的问题分类
- 其他需求
  - Accuracy 精确度
  - 训练时间
  - 线性关系
  - 参数
  - 特征值种类

#### 算法选择 – 从目标出发

Microsoft Azure Machine Learning Algorithm Cheat Sheet

**Multiclass Logistic Regression** 快速、线性模型 精准、需较长时间训练 Multiclass Neural Network 精准、快速 **Multiclass Decision Forest** 选择题(多个里面挑一个) One-vs-ALL Multiclass Multiclass Boosted Decision Tree 无参数、快速、弹性 100个特征值以下、线性 Two-Class Support Vector Machine 你想要... Two-Class Averaged Perceptron 快速、线性模型 精准、快速 Two-Class Decision Forest 是非题(二选一) 快速、线性模型 Two-Class Logistic Regression 精准、快速、较占内存 Two-Class Boosted Decision Tree 精准、需较长时间训练 Two-Class Nwural Network 精准、效能好 图片分类 DenseNet

#### 算法选择 – 从目标出发

Microsoft Azure Machine Learning Algorithm Cheat Sheet

**SVD** Recommender 找出使用者的兴趣、协同过滤 推荐结果生成 非监督式 结构探索 K-Means 100个特征值以下 One Class SVM 找出异常 **PCA-Based Anomaly Detection** 快速 建立字典数据结构 Extract N-Gram Features from Text 你想要... Feature Hashing 使用Vowpal Wabbit library转换 从文字中萃取出信息 **Preprocess Text** 处理stop-word、大小写 转换字词为数值 Word2Vector Fast Forest Quantile Regression 分布预测 Poisson Regression 事件次数预测 快速、线性模型 **Linear Regression** 少量数据可、线性模型 Bayesian Linear Regression 数值预测 快速、精确 **Decision Forest Regression** 训练时间较长、精确 Neural Network Regression 快速、精确、较占内存 **Boosted Decision Tree Regression** 

## 机器学习模型简介

- 预测式算法
  - 从现在与过去的数据来进行预测,例如天气、潜在客户
- 分类算法
  - 给予数据进行训练后,产生一个能够辨别类别的系统
- 时间序列预测算法
  - 概念上与第一类相近,但使用方法不同

## 机器学习运作流程





## 练习:房价预测

sns.distplot(df['Price'])

#### 取得资料 pandas • 遗漏值处理 • 训练 70% read csv • 格式转换 • 测试 30% • 资料观察 #import modules import pandas as pd import numpy as np import matplotlib.pyplot as plt #%matplotlib inline import seaborn as sns #import dataset df = pd.read\_csv("data/Housing\_Dataset\_Sample.csv") #observing dataset df.head() df.describe().T

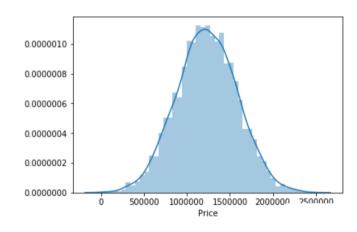
sns.jointplot(df['Avg. Area Income'],df['Price'])

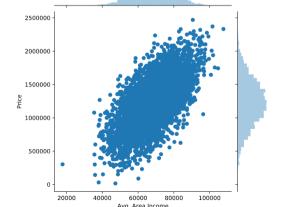
#### 副 模型选择与使

• sklearn

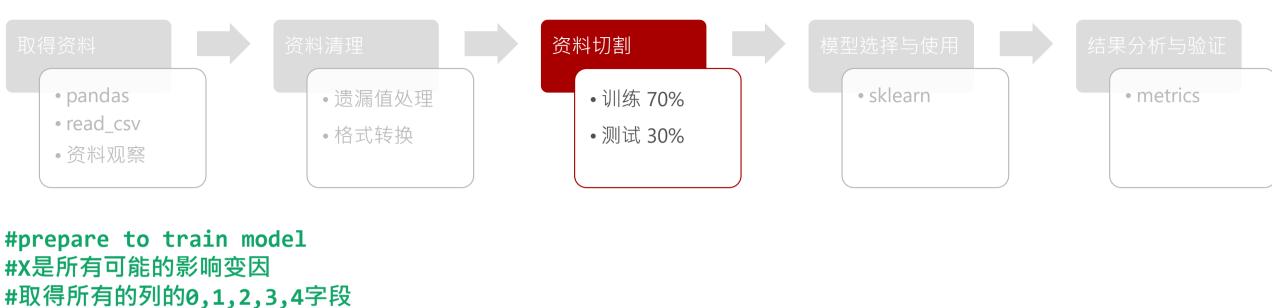
结果分析与验证

metrics





## 练习: 房价预测



```
X = df.iloc[:,:5]
#y是目标值
y = df['Price']

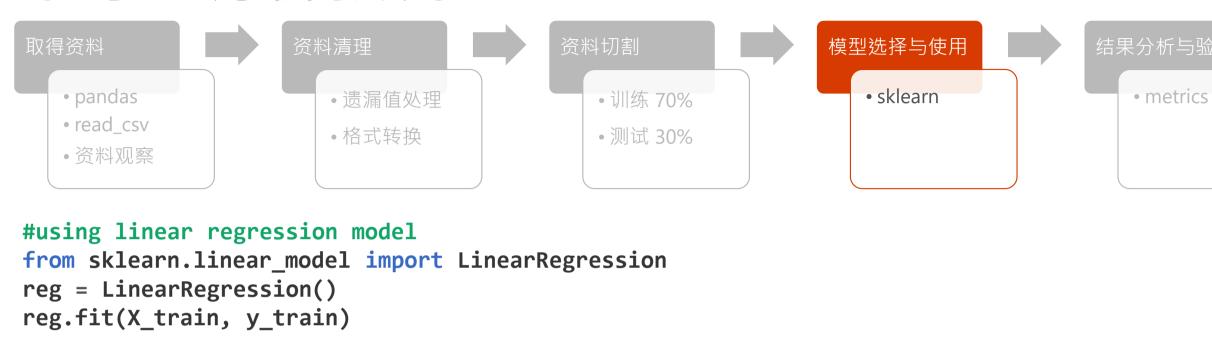
#split to training data & testing data
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.3,random_state=54)
```

## 练习: 房价预测

predictions = reg.predict(X\_test)

#get the result

predictions

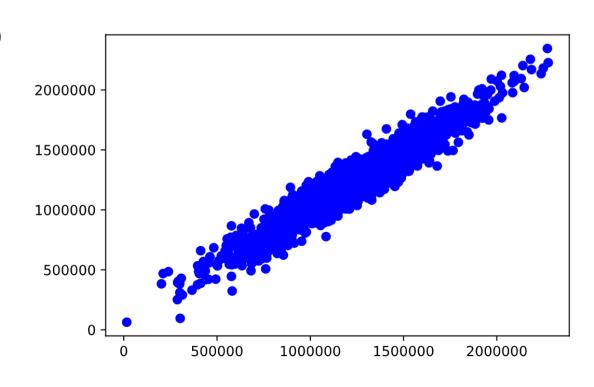


## 练习: 房价预测



```
from sklearn.metrics import r2_score
r2_score(y_test, predictions)
plt.scatter(y_test, predictions, color='blue')
```

0.9216604865707106



#### 

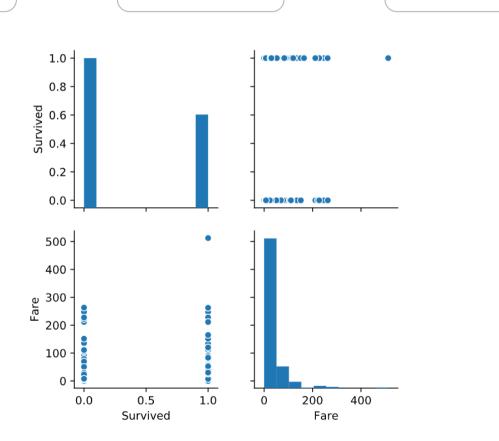
#import modules
<pre>import pandas as pd</pre>
<pre>import numpy as np</pre>
<pre>import matplotlib.pyplot as plt</pre>
#%matplotlib inline
<pre>import seaborn as sns</pre>
<pre>#import dataset df = pd.read_csv("data/train_data_titanic.csv") df.head() df.info()</pre>

域名		说明			
Passengerld		乘客编号			
Survived		是否存活(0: 否、1: 是)			
Pclass	ł	船票等级(1等、2等、3等)			
Name		乘客姓名			
Sex	ı	性别			
Age	1	年龄			
Sibsp	3	有多少兄弟姊妹/配偶在船上			
Parch		有多少父母/小孩在船上			
Ticket	ł	船票编号			
Fare	-	票价			
Cabin	f	舱房编号			
Embark		登船港口 C 瑟堡 Q 皇后镇 S	修咸顿		

metrics

#### 资料清理 • 遗漏值处理 pandas • 训练 70% read csv • 格式转换 • 测试 30% • 资料观察 #Remove the columns model will not use df.drop(['Name','Ticket'],axis=1,inplace=True) df.head() sns.pairplot(df[['Survived','Fare']], dropna=True) #data observing df.groupby('Survived').mean() df.head() df['SibSp'].value\_counts() df['Parch'].value\_counts()

df['Sex'].value\_counts()

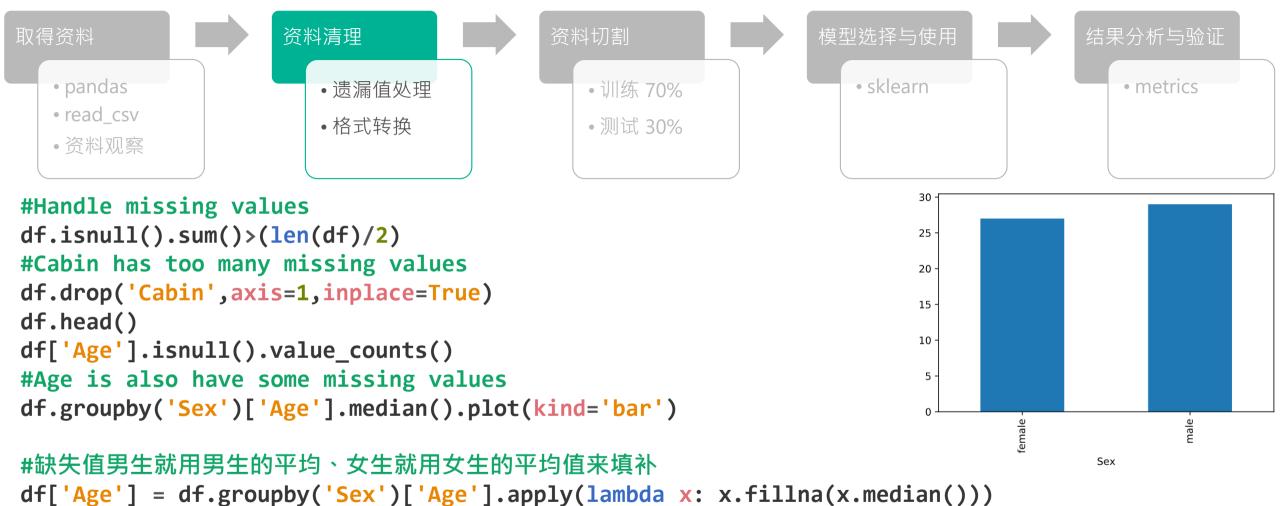


模型选择与使用

sklearn

结果分析与验证

metrics





```
#找出第一个次数最多的,发现是S

df['Embarked'].value_counts().idxmax()

df['Embarked'].fillna(df['Embarked'].value_counts().idxmax(),inplace=True)

df['Embarked'].value_counts()

#所有缺失值搞定!

df.isnull().sum()
```

```
df['Embarked'].value_counts()

S    644
C    168
Q    77
Name: Embarked, dtype: int64
```

```
#将Sex,Embarked进行转换

#Sex转换成是否为男生、是否为女生,Embarked转换为是否为S、是否为C、是否为Q

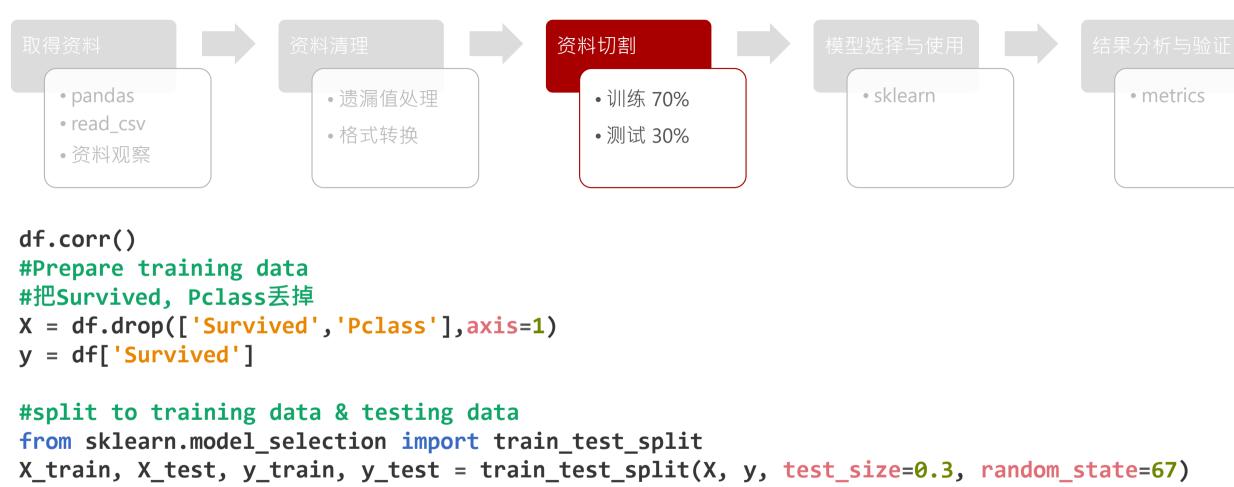
df = pd.get_dummies(data=df, columns=['Sex','Embarked'])

df.head()

#是否为男生与是否为女生只要留一个就好,留下是否为男生

df.drop(['Sex_female'], axis=1, inplace=True)

df.head()
```





```
#using Logistic regression model
from sklearn.linear_model import LogisticRegression
lr = LogisticRegression()
lr.fit(X_train, y_train)
predictions = lr.predict(X_test)
```



#### #Evaluate

```
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score #support是个别tag的真实个数 print(classification_report(y_test,predictions)) print(accuracy_score(y_test, predictions)) print(confusion_matrix(y_test, predictions)) pd.DataFrame(confusion_matrix(y_test, predictions), columns=['True Survived', 'True not Survived'], index=['Predict Survived','Predict not Survived'])
```

	True Survived	True not Survived
Predict Survived	146	16
Predict not Survived	29	77

## 常见评量方式

- 回归
  - mean\_squared\_error
  - mean\_absolute\_error
  - explained\_variance\_score
  - r2\_score
- 分类
  - Precision
  - Recall
  - F1 Score
  - Accuracy

## 常见评量方式

n = 100	预测为No			预测为Yes		
实际上是 No	TN		35	FP	15 (Type I Error)	
实际上是 Yes	FN	5	(Type II Error)	TP	45	

Precision 准确率 = 模型预测为Yes且实际上为Yes 模型预测为Yes的个数

Recall 召回率 = 实际上为Yes而模型也预测为Yes 实际上为Yes的所有个数

F1 Score =  $2 * \frac{Precision * Recall}{Precision + Recall}$ 

Accuracy 精准率 =  $\frac{模型预测为Yes且实际上为Yes+模型预测为No且实际上为No}$ 所有预测的个数

## 使用时间

#### 机率为Yes或No比例相当时,大多数可用Accuracy

• 因为当Yes或No明显比例偏高时,就全部猜那一边Accuracy会大幅提升

#### 怕Type I Error的,要用Precision

- Type I Error 就是预测为Yes但实际为No
- 例如门禁系统把陌生人当成自家人

#### 怕Type II Error的,要用Recall

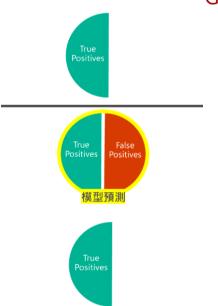
- Type II Error 就是预测为No但实际为Yes
- 例如广告投放判断不是潜在客户但结果却是潜在客户

#### F1 Score 可以避免Precision & Recall的极端误差

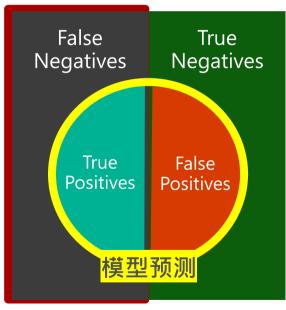
#### Precision & Recall

- Precision 准确率(你的模型判断是对的中,有多少真的是对的)
- Recall 召回率(真的是对的的项目中,你的模型找到几个)
- 准确率是从模型的角度出发、召回率是用真实的状况来看

Recall 召回率 = 实际上为Yes而模型也预测为Yes 实际上为Yes的所有个数



#### **Ground Truth Positives**



## 范例:是否怀孕的判断

#### **Actual Values** 0 TRUE POSITIVE FALSE POSITIVE Predicted Values You're pregnant You're pregnant E 1 ERRO FALSE NEGATIVE TRUE NEGATIVE 0 You're not pregnant You're not pregnant TYPE 2 ERROR

## Recall & Precision练习

#### 模型预测结果



Cat



Dog



Cat

Precision 准确率 = 模型预测为Yes且实际上为Yes 模型预测为Yes的个数

Precision for Cat = ———

Precision for Dog = ———

Precision for Mouse = ————

Precision for Whole Model = 每一种类别的精确率加总 类别数

= \_\_\_\_\_

## Recall & Precision练习

#### 模型预测结果



Cat



Dog



Cat

Recall 召回率 =  $\frac{实际上为Yes而模型也预测为Yes}$ 实际上为Yes的所有个数

Recall for Cat = ————

Recall for Dog = —

Recall for Mouse = ————


Recall for Whole Model = 每一种类别的召回率加总 类别数

**=** \_\_\_\_\_

## Azure Machine Learning 微软Azure机器学习

- 云端环境
- 可以进行模型的训练/部署/自动化/管理/追踪
- 适用于
  - 传统机器学习 / 深度学习 / 监督式学习 / 非监督式学习
- 使用弹性
  - 可自行撰写Python/R 或 使用Azure ML 图形化界面

#### Azure Machine Learning Model Workflow



#### Azure Machine Learning Designer

- 微软Azure机器学习设计师
- 最新推出,以拖拉方式建立机器学习流程

#### Jupyter Notebook

• 可以在云端上使用,上面有许多范例也可以 自己从头建立

#### VS Code Extension 插件

• 可结合本地端运行

#### **CLI Extension**

• 以指令列方式使用

#### Reinforcement learning

• 实验中,使用Ray RLlib



## Reactor







developer.microsoft.com/reactor/
@MSFTReactor on Twitter



# 议程结束感谢的



请记得填写课程回馈问卷 https://aka.ms/ReactorFeedback

© 2019 Microsoft Corporation. All rights reserved. The text in this document is available under the Creative Commons Attribution 3.0 License, additional terms may apply. All other content contained in this document (including, without limitation, trademarks, logos, images, etc.) are not included within the Creative Commons license grant. This document does not provide you with any legal rights to any intellectual property in any Microsoft product. You may copy and use this document for your internal, reference purposes.

This document is provided "as-is." Information and views expressed in this document, including URL and other Internet Web site references, may change without notice. You bear the risk of using it. Some examples are for illustration only and are fictitious. No real association is intended or inferred. Microsoft makes no warranties, express or implied, with respect to the information provided here.